Mini Project 1

Goal

- 大致了解compiler的架構
- 了解從高階語言至組合語言的過程
- Trace code能力與實作能力

Compiler 架構

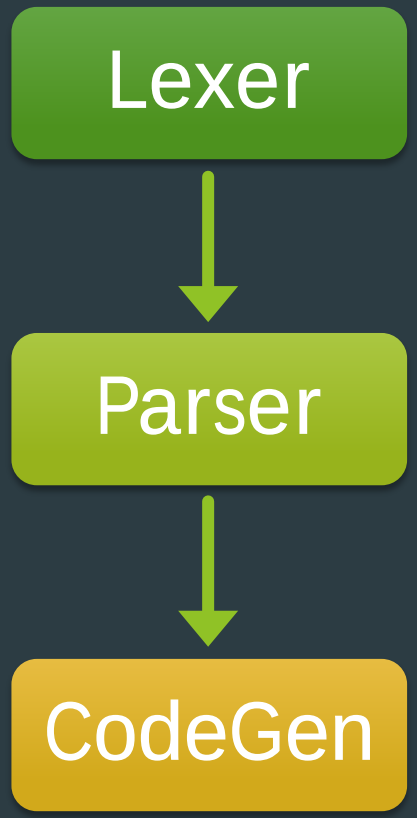

Compiler 架構

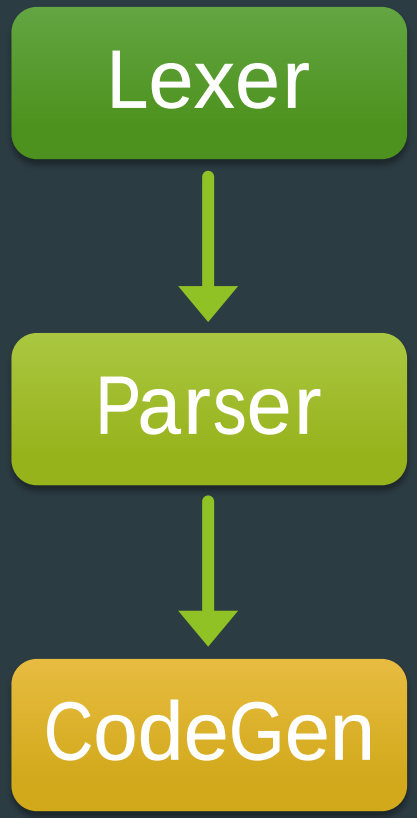

Lexer (Lexical Analyzer)

- 將input切成一個一個的token以利後續處理。
  - Input: `x=y+++5`
  - Token:

```
Identifier (x)
Assign     (=)
Identifier (y)
PostInc    (++)
Add        (+)
Constant   (5)
```

Compiler 架構

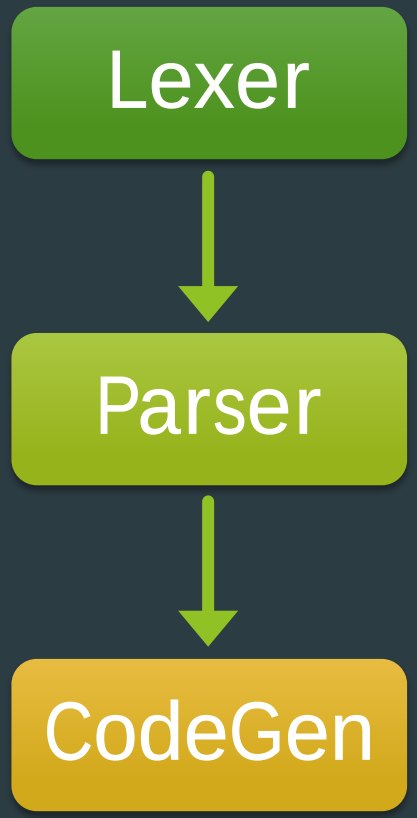

Parser

- 根據grammar rule，利用tokens建立出正確的AST(Abstract Syntax Tree)。
  - Token:

```
Identifier (x)
Assign     (=)
Identifier (y)
PostInc    (++)
Add        (+)
Constant   (5)
```

  - AST:

```
Assign (=)                  --root是"="
  ├ Identifier (x)          --"="的左邊是"x"
  └ Add (+)                 --"="的右邊是"+"
      ├ PostInc (++)        --"+"的左邊是"++"
      │   └ Identifier (y)  --"++"跟著"y"
      └ Constant (5)        --"+"的右邊是"5"
```

Compiler 架構

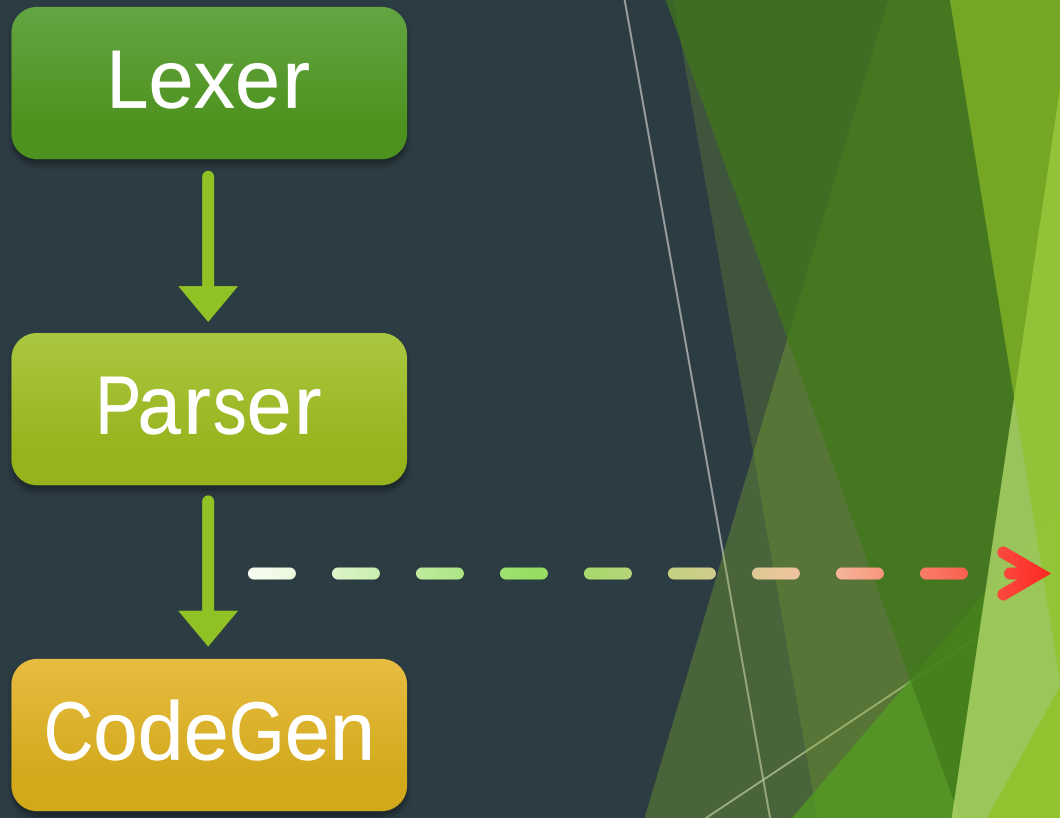

semantic check

- 確認生成的AST是否有語意錯誤
  - AST:

```
Assign (=)
  ├ Identifier (x)
  └ Add (+)
      ├ PostInc (++) → PostInc必須接Identifier
      │   └ Identifier (y) → OK
      └ Constant (5)
```

  - AST:

```
Assign (=)
  ├ Identifier (x)
  └ Add (+)
      ├ PostInc (++) → PostInc必須接Identifier
      │   └ Constant (9) → Semantical error!
      └ Constant (5)
```

Compiler 架構

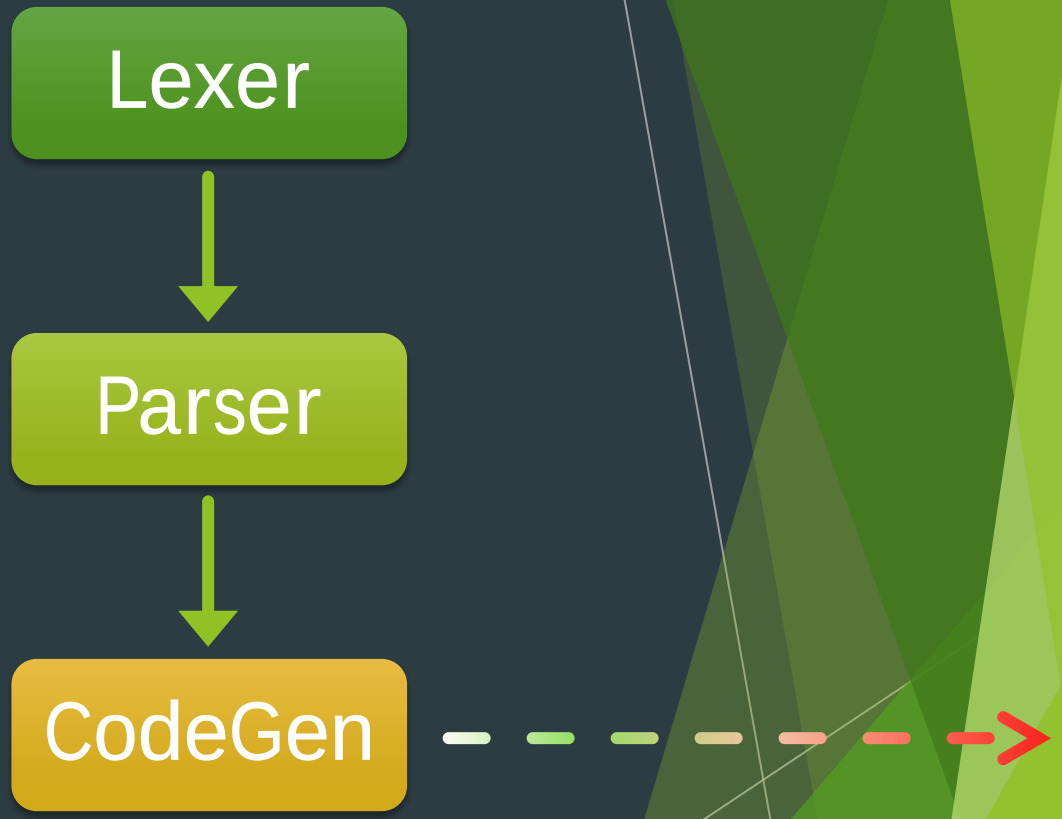

CodeGen

- 利用建立的AST，把ASM生出來。
  - AST:

```
Assign
 ├ Identifier (x)
 └ Add (+)
    ├ PostInc (++)
    │  └ Identifier (y)
    └ Constant (5)
```

  - ASM:

```
load "y" into r0
add r0 and 1 into r1      y++
store r1 into "y"
add 0 and 5 into r1       5
add r0 and r1 into r0     y+++5
store r0 into "x"         x=y+++5
```

Compiler 架構

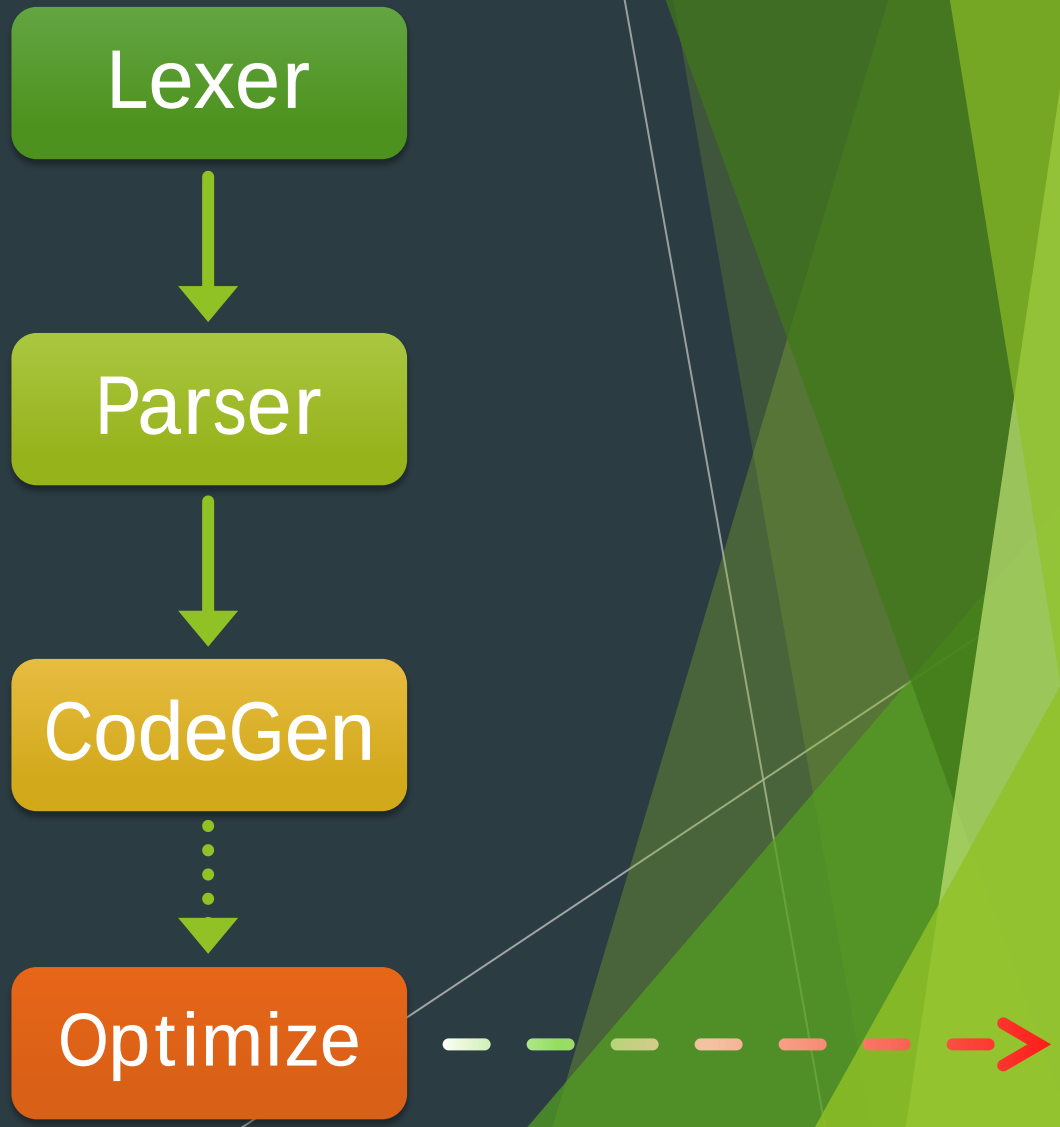

Optimization

- 優化生出來的ASM，使其所耗的cycle數更少。
  - ASM:

```
load "y" into r0
add r0 and 1 into r1
store r1 into "y"
add 0 and 5 into r1
add r0 and r1 into r0
store r0 into "x"
```

  - After optimization:

```
load "y" into r0
add r0 and 1 into r1
store r1 into "y"
add r0 and 5 into r0
store r0 into "x"
```

Code Trace – main()

```
int main() {
    while (fgets(input, MAX_LENGTH, stdin) != NULL) {
        Token *content = lexer(input);
        size_t len = token_list_to_arr(&content);
        AST *ast_root = parser(content, len);
        semantic_check(ast_root);
        codegen(ast_root);
        free(content);
        freeAST(ast_root);
    }
    return 0;
}
```

逐行吃輸入(進input)&處理

將input轉為Token linked list

方便起見，linked list轉為array

用Token array建AST

執行semantic check

Generate ASM code

釋放記憶體: Token array

釋放記憶體: AST tree

Optimization在這裡!

Code Trace – lexer(const char*)

- Token:
  - Identifier(x), Assign(=), Identifier(y), PostInc(++), Add(+), Constant(5)

```
typedef struct TokenUnit {
    Kind kind;
    int val;
    struct TokenUnit *next;
} Token;
```

- struct Token (linked list):

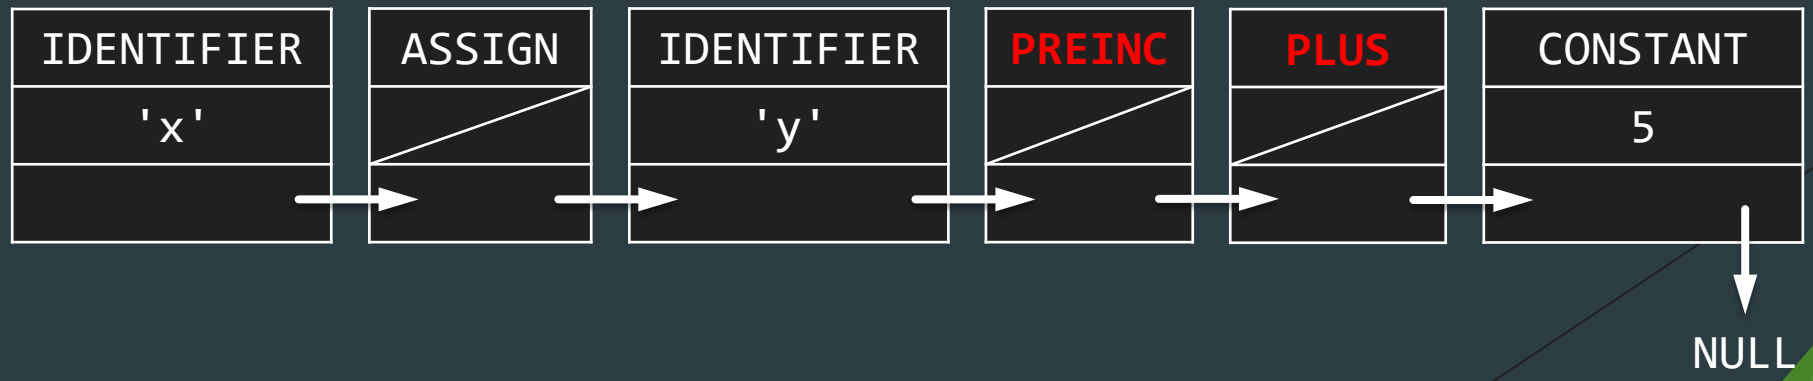

Code Trace – lexer(const char*)

- lexer不會辨認是PostInc還是PreInc，只會辨認為"++"。
  - 方便起見，統一設kind = PreInc，PostDec/PreDec同理。
- lexer不會辨認是Plus還是Add，只會辨認為"+"。
  - 方便起見，統一設kind = Plus，Minus/Sub同理。
- 在parser建完AST的時候，這些就會全部被定位出來。

Code Trace – token_list_to_arr(Token**)

- struct Token (linked list):

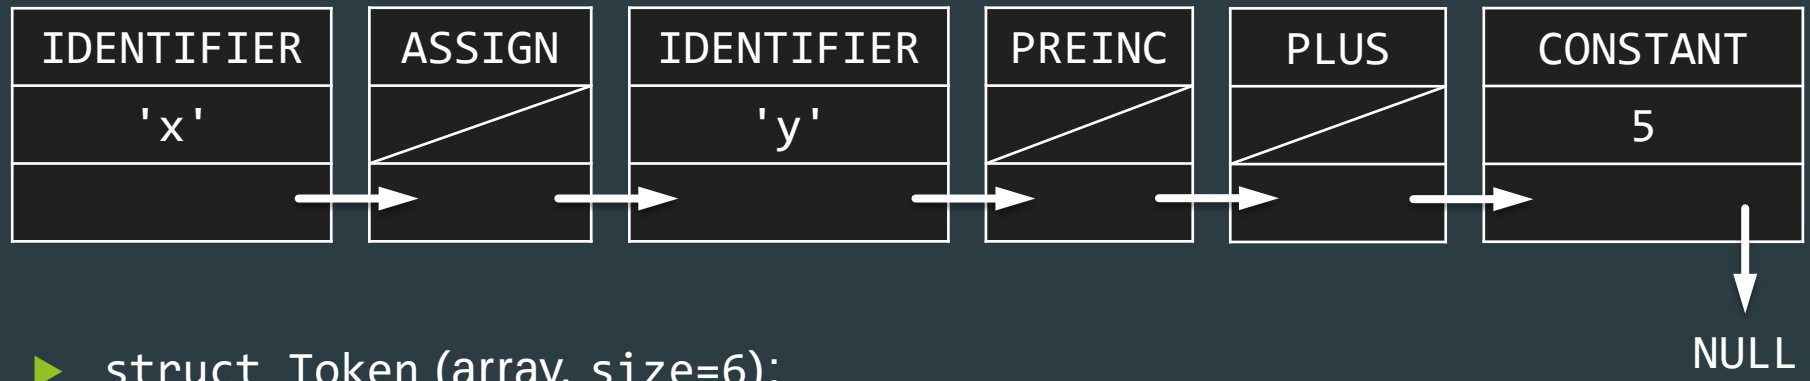

- struct Token (array, size=6):

Index	0	1	2	3	4	5
kind	IDENTIFER	ASSIGN	IDENTIFER	PREINC	PLUS	CONSTANT
val	'x'		'y'			5
next						

Code Trace – parser(Token*, size_t)

- lexer無法辨別的PLUS/ADD和MINUS/SUB，在parser先行辨別。

- 辨別後再呼叫parse正式開始構建AST。

```
AST *parser(Token *arr, size_t len)
```

回傳構建完成的AST的root

傳入先前建好的Token array

傳入array的長度

Code Trace – parse(Token*, int, int, GrammarState)

- 遵照grammar rule構建AST。

```
switch (S) {
    case STMT:
        ......
    case EXPR:
        ......
    case ASSIGN_EXPR:
        ......
    case ADD_EXPR:
        ......
    case ......
        ......
    case PRI_EXPR:
        ......
}
```

```
AST *parse(Token *arr, int l, int r, GrammarState S)
```

回傳當前範圍建出的AST

整個Token array

arr的範圍: 左界

arr的範圍: 右界

當前的state

Code Trace – parse(Token*, int, int, GrammarState)

- 先嘗試走 ASSIGN_EXPR -> UNARY_EXPR ASSIGN ASSIGN_EXPR 的路線。
- 找不到(if (nxt != -1))則當作 ADD_EXPR 往下走。
- 其餘state類似。

```
ASSIGN_EXPR
    → ADD_EXPR
    | UNARY_EXPR ASSIGN ASSIGN_EXPR
    ;
```

```
case ASSIGN_EXPR:
    if ((nxt = findNextSection(arr, l, r, condASSIGN)) != -1) {
        now = new_AST(arr[nxt].kind, 0);
        now->lhs = parse(arr, l, nxt - 1, UNARY_EXPR);
        now->rhs = parse(arr, nxt + 1, r, ASSIGN_EXPR);
        return now;
    }
    return parse(arr, l, r, ADD_EXPR);
```

Code Trace – parse(Token*, int, int, GrammarState)

- 第1/2個TODO在這裡！
  - 完成MUL_EXPR的parse
  - 完成UNARY_EXPR的parse

```
MUL_EXPR
    → ...
    ;
UNARY_EXPR
    → ...
    ;
```

- Hint:
  - 參考grammar rule
  - 參考其他state如何進行

```
case MUL_EXPR:
    // TODO: Implement MUL_EXPR.
    // hint: Take ADD_EXPR as reference.
case UNARY_EXPR:
    // TODO: Implement UNARY_EXPR.
    // hint: Take POSTFIX_EXPR as reference.
```

Code Trace – semantic_check(AST*)

- 檢查有沒有semantical error。
  - '='的左邊只能是Identifier或是被括號層層包圍的Identifier。
    - ((((((z))))))=x+y
  - '++'/'--'的底下只能是Identifier或是被括號層層包圍的Identifier。
    - ((((x))))++, --(((((y))))), ++z

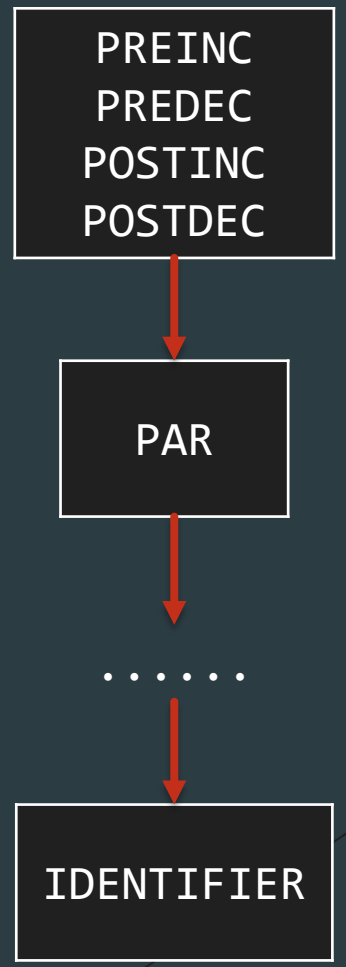

Code Trace – semantic_check(AST*)

- 第3個TODO在這裡！
  - ASSIGN已經完成了，完成剩餘部份的semantic_check code。
- Hint:
  - 還剩下INC/DEC的部份
  - semantic_check需要檢查所有AST node，如何做到?

```
// Operand of INC/DEC must be an identifier or identifier with on
e or more parentheses.
// TODO: Implement the remaining semantic_check code.
// hint: Follow the instruction above and ASSIGN-
part code to implement.
// hint: Semantic of each node needs to be checked recursively (f
rom the current node to lhs/mid/rhs node).
```

Code Trace – codegen(AST*)

- 給定AST root，生出對應的ASM。
- 第4個TODO在這裡！
  - 完成整個codegen
  - codegen形式自由，你可以改parameter、return type，甚至整個結構
    - ~~其實你想重寫一份都可以~~
  - 直接輸出ASM，或是寫個ASM structure方便管理?
- Hint:
  - 整顆AST這麼大，我應該從哪開始生起?

```
void codegen(AST *root) {
    // TODO: Implement your codegen in your own way.
    // You may modify the function parameter or the return type,
even the whole structure as you wish.
}
```

Code Trace – utility interfaces

- 提供各式各樣的function以利實作。

- err(x):
  - 輸入的expression不符合grammar / 無法通過semantic check時呼叫。
  - DEBUG改為1可以方便看到錯誤產生在code的哪一行，上傳前要改回0。

```
#define err(x) {\
    puts("Compile Error!");\
    if(DEBUG) {\
        fprintf(stderr, "Error at line: %d\n", __LINE__);\
        fprintf(stderr, "Error message: %s\n", x);\
    }\
    exit(0);\
}
#define DEBUG 0
```

Code Trace – debug interfaces

- 提供debug function以利除錯。

```
// Print token array.
void token_print(Token *in, size_t len);
// Print AST tree.
void AST_print(AST *head);
```

將Token array與其長度輸入，就會自動輸出所有Token。

將建立完成的AST的root，就會自動以樹狀結構輸出AST。

ISA Introduction

- 包含7種instruction:
  - `add` 加法運算
  - `sub` 減法運算
  - `mul` 乘法運算
  - `div` 除法運算
  - `rem` 模運算(%)
  - `load` 將指定位置的memory資料存進指定位置的register中
  - `store` 將指定位置的register資料存進指定位置的memory中

ISA Introduction

- add: 花費10 cycle。
  - add r0 r2 r7: 將r2與r7的值相加，並存在r0中。
    - 若r2=10, r7=1024, add執行完後，r0=r2+r7=1034。
  - add r0 1 2: 將r0的值設為1+2。
    - 輸入的數值只能是**非負整數**(register和memory存的value沒關係)。
- 其他的(sub, mul, div, rem)也類似。
- sub: 花費10 cycle
- mul: 花費30 cycle
- div: 花費50 cycle
- rem: 花費60 cycle

ISA Introduction

- load: 花費200 cycle
  - load r1 [4]: 將memory [4]的值存進register r1中。
    - 若[4]=18, load執行完後，r1=18。
- store: 花費200 cycle
  - store [8] r3: 將register r3的值存進memory [8]中。
    - 若r3=-12, store執行完後，[8]=-12。

ISA Introduction

- 變數: 僅x, y, z三個，分別存在memory [0], [4], [8]中。
- register限制: 可使用r0 – r255，但使用r8或以上的register將會有penalty。
  - mul cycle為30，但若是mul r0 r12 r13，則cycle倍增為60。
- "Compile Error!": 程式吃到錯誤的expression時應輸出此instruction。
  - 可以直接使用Macro err(x)來輸出並結束程式。

Assembly Compiler

- ASMC – Assembly Compiler，逐行輸入ASM，直到EOF時會吐出x, y, z最後的值與總耗費cycle數。
  - x, y, z初始設定為2, 3, 5
  - x, y, z可自訂初值，詳細設定參考github page。
- 由於是用C++編寫，編譯請照github page上的步驟做。
- 務必利用ASMC做debug，會有極大的幫助。

```
load r0 [4]
add r0 r0 5
store [8] r0
x, y, z = 2, 3, 8
Total cycle = 410
```

評分

- 占**總成績 8%**
- 一共24個testcases，其中有6個basic testcases公布在github page上。
- 24筆testcases全過的同學中，總耗費cycle數最低的前10%會拿到**總成績2分**的bonus。
- 使用ASMC搭配python script做評分，一切以ASMC的輸出為準。
  - 評分時`(x,y,z)`初始值不會是`(2,3,5)`，而是`[-100,100]`的隨機值。 ~~偷吃步不用想子~~

Submission / Demo

- 11/06(三) 晚上11:59前繳交code
  - 上傳到iLMS並命名為 `mini1.c`
- demo time: 11/07(四) 晚上06:30起
  - 務必出席，若有事無法前來請事先告知。
  - Demo結束後會在一定時間內公布通過的測資數與cycle數比賽的結果。
- 若違反上述規則(未命名成`mini1.c` / 未出席demo ...etc)，TA有權斟酌扣分。情節重大者(抄襲 ...etc)可能會重罰或上報校方。

Questions?

補充 - optimization

- 盡可能地透過重新編排、計算已知等手段，使ASM得以能夠在減少總耗費cycle數的**同時保持著運算的正確性**。
- 通常在codegen生完ASM時才進行。

optimization通常在這裡

```
Token *content = lexer(input);
size_t len = token_list_to_arr(&content);
AST *ast_root = parser(content, len);
semantic_check(ast_root);
codegen(ast_root);
free(content);
freeAST(ast_root);
```

補充 - optimization

```
x=(2+3)/10*5%2-31
```

codegen

```
add r0 2 3
div r0 r0 10
mul r0 r0 5
rem r0 r0 2
sub r0 r0 31
store [0] r0
```

optimization

```
sub r0 0 31
store [0] r0
```

可以算的先算掉，能少掉很多inst

```
x=(x+(y-
(z*(x/(y%(z+(x-
(y*(z/(x%(y+(z-
(x*(y/(z%5)))))))
))))))))
```

```
x=5+x
y=x*x-(12*12)
```

補充 - optimization

```
x=(2+3)/10*5%2-31
```

```
x=(x+(y-
(z*(x/(y%(z+(x-
(y*(z/(x%(y+(z-
(x*(y/(z%5)))))))
))))))))
```

```
x=5+x
y=x*x-(12*12)
```

codegen

```
load r0 [0]
load r1 [4]
......
load r14 [8]
rem r14 r14 5
......
```

補充 - optimization

```
x=(2+3)/10*5%2-31
```

```
x=(x+(y-
(z*(x/(y%(z+(x-
(y*(z/(x%(y+(z-
(x*(y/(z%5)))))))
))))))))
```

```
x=5+x
y=x*x-(12*12)
```

codegen

```
load r0 [0]
load r1 [4]
......
load r14 [8]
rem r14 r14 5
......
```

optimization

```
load r0 [8]
rem r0 r0 5
load r1 [4]
div r0 r1 r0
......
```

不相關的insts可以交換，而不影響結果

補充 - optimization

```
x=(2+3)/10*5%2-31
```

```
x=(x+(y-
(z*(x/(y%(z+(x-
(y*(z/(x%(y+(z-
(x*(y/(z%5)))))))
))))))))
```

```
x=5+x
y=x*x-(12*12)
```

codegen

```
load r0 [0]
add r0 r0 5
store [0] r0
load r0 [0]
load r1 [0]
mul r0 r0 r1
......
```

optimization

```
load r0 [0]
add r0 r0 5
store [0] r0
mul r0 r0 r1
......
```

已經存在register上的value可以重複利用

補充 - optimization

```
x=(x+(y-
(z*(x/(y%(z+(x-
(y*(z/(x%(y+(z-
(x*(y/(z%5)))))))
))))))))
x=3
```

codegen

```
......
add r0 0 3
store [0] r0
```

optimization

```
add r0 0 3
store [0] r0
```

不影響最後結果的expression可以拿掉

```
z=z*(z-z)
```

```
x=y++
x=3
```

```
x=y+10
z=x+3
x=3
```

補充 - optimization

```
x=(x+(y-
(z*(x/(y%(z+(x-
(y*(z/(x%(y+(z-
(x*(y/(z%5)))))))
))))))))
x=3
```

```
z=z*(z-z)
```

```
x=y++
x=3
```

```
x=y+10
z=x+3
x=3
```

codegen

```
load r0 [8]
load r1 [8]
load r2 [8]
sub r1 r1 r2
......
```

optimization

```
add r0 0 0
store [8] r0
```

未知的variable也可以得到已知的結果

補充 - optimization

```
x=(x+(y-
(z*(x/(y%(z+(x-
(y*(z/(x%(y+(z-
(x*(y/(z%5)))))))
))))))))
x=3
```

```
z=z*(z-z)
```

```
x=y++
x=3
```

```
x=y+10
z=x+3
x=3
```

codegen

```
load r0 [4]
add r0 r0 1
store [4] r0
store [0] r0
add r0 0 3
store [0] r0
```

optimization 錯誤

```
add r0 0 3
store [0] r0
```

看似不影響，但其實影響了y的值

補充 - optimization

```
x=(x+(y-
(z*(x/(y%(z+(x-
(y*(z/(x%(y+(z-
(x*(y/(z%5)))))))
))))))))
x=3
```

```
z=z*(z-z)
```

```
x=y++
x=3
```

```
x=y+10
z=x+3
x=3
```

codegen

```
load r0 [4]
add r0 r0 1
store [4] r0
store [0] r0
add r0 0 3
store [0] r0
```

optimization

```
load r0 [4]
add r0 r0 1
store [4] r0
add r0 0 3
store [0] r0
```

依然能優化，存值最後做就好

如果中間還有用到x，務必要在register留下紀錄

補充 - optimization

```
x=(x+(y-
(z*(x/(y%(z+(x-
(y*(z/(x%(y+(z-
(x*(y/(z%5)))))))
))))))))
x=3
```

```
z=z*(z-z)
```

```
x=y++
x=3
```

```
x=y+10
z=x+3
x=3
```

codegen

```
load r0 [4]
add r0 r0 10
store [0] r0
load r0 [0]
......
```

optimization

```
load r0 [4]
add r0 r0 10
add r1 r0 3
store [8] r1
......
```

中間用到了x，只能部分優化

補充 - optimization

```
x=(x+(y-
(z*(x/(y%(z+(x-
(y*(z/(x%(y+(z-
(x*(y/(z%5)))))))
))))))))
x=3
```

```
z=z*(z-z)
```

```
x=y++
x=3
```

```
x=y+10
z=x+3
x=3
```

codegen

```
load r0 [4]
add r0 r0 10
store [0] r0
load r0 [0]
......
```

optimization

```
load r0 [4]
add r0 r0 10
add r1 r0 3
store [8] r1
......
```

optimization

```
load r0 [4]
add r1 r0 13
store [8] r1
add r0 0 3
store [0] r0
```

還可以更進一步多做一點

補充 - optimization

- 哪些可以省略? 哪裡可以縮短? reg用得太多怎麼處理?
- Compiler課程會講更多有關optimization的細節。
- Instruction數量減少與cycle減少之餘，最重要的是**保持正確性**。

Questions?